UNIVERSIDADE DE SÃO PAULO (USP)
FACULDADE DE FILOSOFIA, LETRAS E CIÊNCIAS HUMANAS (FFLCH)
Departamento de Linguística — Grupo Experimental em Semiótica Computacional (SemioCom)

RELATÓRIO CIENTÍFICO FINAL DE INICIAÇÃO CIENTÍFICA

Relatório Científico Final de Iniciação Científica (Edição Pública — Ciência Aberta)

CONTRIBUIÇÕES DA SEMIÓTICA PARA A ANÁLISE ASPECTUAL DE SENTIMENTOS

Discente: Vinicius de Andrade Rosa | **Nº USP:** FFLCH / USP

Orientador(a) Institucional (Sistema Atena): Prof. Dr. Waldir Beividas | **Nº USP:** Departamento de Linguística — FFLCH / USP

Supervisão SemioCom: Me. Túlio Ferreira Leite da Silva (Coordenador Executivo — SemioCom / FFLCH-USP)

Modalidade / Agência de Fomento: Iniciação Científica Voluntária (Sem Bolsa / Sem Fomento Externo)

Período de Vigência: Setembro de 2025 a Setembro de 2026

São Paulo
2026

RESUMO

A Análise de Sentimentos Baseada em Aspectos (ABSA) clássica restringe a qualificação afetiva a categorias discretas estáticas (positivo, negativo, neutro), revelando-se insuficiente diante de figuras de linguagem, concessões sintáticas e variações contínuas de intensidade emocional. Mesmo em formulações dimensionais recentes, como o benchmark internacional SemEval-2026 Task 3 (DimABSA), Modelos de Linguagem de Grande Escala (LLMs) operando sem ajuste fino (zero-shot) capturam adequadamente o eixo de Valência (satisfação), mas colapsam sistematicamente na predição de Arousal (excitação/tonicidade). Esta Iniciação Científica investigou a hipótese de que as quantificações subjetivas e direções tensivas da Semiótica Tensiva (Zilberberg, 2006, 2012; Tatit, 2011; Silva, 2021, 2023) — Atenuação, Minimização, Redobramento, Saturação, Extinção e Restabelecimento/Constatação Átona — fornecem uma gramática estrutural capaz de calibrar a inferência dimensional de LLMs. A trajetória experimental abrangeu quatro etapas: (i) linha de base discreta no SemEval-2014 Task 4 com Mistral-7B-Instruct-v0.3 (acurácia de 75,33%); (ii) participação oficial na competição SemEval-2026 Task 3 (Track A, Subtask 1 — Laptop), alcançando RMSE_VA = 1,9483 e diagnosticando o gargalo crítico de Arousal (PCC_A = 0,0853); (iii) bateria exploratória multi-modelos seguida de auditoria rigorosa que identificou e eliminou riscos de vazamento amostral (data leakage); e (iv) proposição e validação da Decomposição Semiótica Ancorada ao Aspecto (DSAA v2) em protocolo triplamente controlado (N = 178 aspectos em 146 sentenças cegas, modelo Qwen2.5-7B-Instruct 4-bit, Seed = 2026). Os resultados comprovam que sentenças com tensão concessiva/figurativa dobram a chance de erro severo no baseline (30,6% vs. 16,4%; Odds Ratio = 2,25; Teste Exato de Fisher p = 0,0494), vulnerabilidade reduzida para 14,4% (-52,9% relativo) pelo DSAA v2. Globalmente, a abordagem semiótica reduziu o RMSE_VA oficial de 2,1132 (Baseline Direto) e 1,7571 (Controle Chain-of-Thought Lexical de mesmo orçamento) para 1,2926 (1,3033 no dev oficial cego, superando o 9º lugar supervisionado da competição sem ajuste de pesos), elevando a correlação de Arousal para PCC_A = 0,5541, com 80,3% de vitórias individuais (Wilcoxon $p = 2{,}44 \times 10^{-19}$) e reconstruindo empiricamente a curva parabólica em 'U' prevista pela teoria tensiva de Zilberberg.

Palavras-chave: Análise Aspectual de Sentimentos; Semiótica Tensiva; Quantificações Subjetivas; Modelos de Linguagem de Grande Escala; SemEval-2026 DimABSA.

ABSTRACT

Classical Aspect-Based Sentiment Analysis (ABSA) constrains affective qualification to static discrete categories (positive, negative, neutral), failing under figurative language, syntactic concessions, and fine-grained intensity shifts. Even in continuous dimensional formulations such as SemEval-2026 Task 3 (DimABSA), zero-shot Large Language Models (LLMs) accurately track Valence but systematically collapse along the Arousal (tonicity) axis. This undergraduate research investigated whether subjective quantifications and tensive directions from Tensive Semiotics (Zilberberg, 2006, 2012; Tatit, 2011; Silva, 2021, 2023) — Attenuation, Minimization, Redoubling, Saturation, Extinction, and Atonic Statement — provide an explicit structural grammar to calibrate dimensional LLM inference. Across four experimental stages culminating in our Aspect-Anchored Semiotic Decomposition (DSAA v2) evaluated under a strictly leakage-free triple-controlled protocol (N = 178 aspects across 146 sentences, Qwen2.5-7B-Instruct 4-bit, Seed = 2026), we show that concessive/tensive phenomena double severe baseline failures (30.6% vs. 16.4%, OR = 2.25, Fisher p = 0.0494), which DSAA v2 cuts to 14.4%. DSAA v2 lowers official RMSE_VA from 2.1132 (Direct Baseline) and 1.7571 (matched-budget Lexical CoT Control) to 1.2926 (1.3033 on blind official dev, matching top-10 supervised systems without fine-tuning), raises Arousal correlation to PCC_A = 0.5541 (80.3% pairwise win-rate, Wilcoxon $p = 2.44 \times 10^{-19}$), and empirically reconstructs Zilberberg's parabolic U-curve in the continuous Valence-Arousal plane.

Keywords: Aspect-Based Sentiment Analysis; Tensive Semiotics; Subjective Quantifications; Large Language Models; Dimensional Sentiment Regression.

1. INTRODUÇÃO E CONTEXTUALIZAÇÃO DO PROBLEMA

A Análise de Sentimentos Baseada em Aspectos (ABSA, do inglês Aspect-Based Sentiment Analysis) constitui uma subárea central do Processamento de Linguagem Natural (PLN) dedicada a decompor opiniões textuais segundo as entidades e os atributos específicos avaliados pelo enunciador (Hu; Liu, 2004; Liu, 2012). Embora tenha superado a limitação dos classificadores holísticos em nível de documento — incapazes de distinguir elogios e críticas coexistentes numa mesma resenha —, a formulação canônica da ABSA herdou um pressuposto epistemológico restritivo: a redução do afeto à tríade estática de polaridades positivo, negativo e neutro (Pontiki et al., 2014).

Em corpora reais de avaliações de consumidores, essa grade categórica mostra-se fragilizada diante de dois fenômenos discursivos recorrentes: (i) figuras de linguagem, como ironia, metáfora e sarcasmo, nas quais o sentido enunciativo inverte ou desloca o valor literal dos itens lexicais (Shangipour Ataei et al., 2020; Derbala Yacoub et al., 2024); e (ii) construções concessivas, adversativas e de polaridade mista, nas quais múltiplos aspectos competem em diferentes graus de aprovação ou restrição dentro do mesmo período sintático. Estudos recentes demonstram que até mesmo Modelos de Linguagem de Grande Escala (Large Language Models — LLMs), apesar de sua expressiva capacidade generativa, sofrem quedas acentuadas de desempenho em tarefas estruturadas de ABSA fina quando operam sem balizas teóricas explícitas (Zhang et al., 2023).

O presente projeto de Iniciação Científica, desenvolvido junto ao Grupo Experimental em Semiótica Computacional (SemioCom) da Faculdade de Filosofia, Letras e Ciências Humanas da Universidade de São Paulo (FFLCH-USP) na modalidade voluntária (sem fomento externo), partiu da hipótese de que a Semiótica Tensiva (Zilberberg, 2006, 2012; Tatit, 2011) e, especificamente, o sistema de quantificações subjetivas e direções tensivas formulado por Silva (2021, 2023) oferecem um modelo descritivo rigoroso para suprir essa lacuna semântica. Em vez de tratar o sentimento como rótulo estático de senso comum (Hjelmslev, 1969), a gramática tensiva modela o valor discursivo pela articulação dinâmica entre intensidade (tonicidade e andamento) e extensidade (concentração e difusão).

Ao longo dos doze meses de vigência (setembro de 2025 a setembro de 2026), os objetivos propostos no plano original foram integralmente cumpridos e ampliados pela inserção do projeto na competição internacional SemEval-2026 Task 3 — Dimensional Aspect-Based Sentiment Analysis (DimABSA; Yu et al., 2026; Lee et al., 2026). A transição da ABSA discreta (SemEval-2014) para o espaço contínuo bidimensional de Valência e Arousal (Russell, 1980) permitiu testar uma hipótese ainda mais forte e falsificável: verificar se as seis categorias tensivas de Silva (2021) funcionam como coordenadas estruturais capazes de corrigir o colapso crônico de LLMs zero-shot na predição de Arousal (tonicidade afetiva) e desacoplar avaliações concessivas multi-aspecto.

2. FUNDAMENTAÇÃO TEÓRICA E METODOLOGIA

2.1 Da Quíntupla de Bing Liu ao Espaço Tensivo de Zilberberg e Silva

Na formalização clássica de Liu (2012), uma opinião é definida pela quíntupla g = (e, a, s, h, t), compreendendo a entidade-alvo (e), o aspecto avaliado (a), o sentimento atribuído (s), o detentor da opinião (h) e a referência temporal (t). Conforme sistematizado na etapa conceitual desta pesquisa, substituir o componente estático s por um estado tensivo produz uma Quíntupla Semioticamente Enriquecida, na qual a pergunta estrutural da ABSA ('sobre qual aspecto se opina?') converge com a pergunta semântica da Semiótica ('sob qual regime de tensão e intensidade se constrói a sanção discursiva?').

Segundo Zilberberg (2006, 2012) e Tatit (2011), o espaço tensivo organiza-se em torno da correlação entre a intensidade regente (estados de alma, impacto sensível, tonicidade) e a extensidade regida (estados de coisas, desdobramento quantitativo e concessivo). Operacionalizando esse arcabouço para resenhas digitais em PLN, Silva (2021, 2023) estabeleceu seis direções tensivas que recobrem o contínuo afetivo-discursivo: (1) Extinção: ruptura disfórica extrema e rejeição categórica de altíssima tonicidade; (2) Minimização: sanção predominantemente disfórica e tônica que restringe ou deprecia o valor do aspecto; (3) Constatação Átona / Restabelecimento: registro descritivo, factual ou funcionalmente neutro sob mínima tonicidade; (4) Atenuação: desaceleração concessiva ou abrandamento ('razoável, mas...', 'um pouco caro'), mitigando o impacto tônico; (5) Redobramento / Recrudescimento: expansão eufórica consistente e aprovação sustentada; e (6) Saturação: ápice tônico hiperbólico e exclamação superlativa de excelência.

No paradigma dimensional adotado pelo SemEval-2026 Task 3 (Yu et al., 2026), cada aspecto recebe coordenadas reais no intervalo [1,00; 9,00] para Valência (V: desprazer extremo = 1 a prazer extremo = 9) e Arousal (A: atonia/calma = 1 a excitação/tensão máxima = 9). Sob a ótica semiótica aqui defendida, a relação entre V e A em avaliações humanas não é linear, mas parabólica (curva em 'U'): tanto a consagração eufórica (Saturação) quanto a ruptura disfórica (Extinção e Minimização) exigem alta tonicidade (A elevado), ao passo que o centro neutro (Constatação Átona) repousa no mínimo global de Arousal.

2.2 Arquitetura Experimental em Quatro Etapas e Auditoria Anti-Vazamento

A metodologia empírica seguiu um desenho progressivo em quatro etapas, combinando participação em avaliação competitiva internacional com ablação causal estritamente controlada:

Etapa 1 (ABSA Discreta — SemEval-2014 Task 4): Avaliação zero-shot do modelo aberto Mistral-7B-Instruct-v0.3 (quantização NF4 4-bit, temperatura próxima de zero e saída JSON estruturada) em 800 resenhas de restaurantes convertidas de XML, cobrindo as Subtasks 2 (polaridade de termo de aspecto, N = 916) e 4 (polaridade de categoria, N = 900).

Etapa 2 (Competição Internacional SemEval-2026 Task 3 — DimABSA): Participação oficial via plataforma Codabench na Track A, Subtask 1 (Dimensional Aspect Sentiment Regression — DimASR). Dado o texto e o aspecto-alvo, o sistema prevê (V, A) avaliados pela métrica oficial RMSE_VA = raiz_quadrada(media((V - V_pred)^2 + (A - A_pred)^2)) e pelas correlações de Pearson PCC_V e PCC_A. A submissão oficial no domínio eng_laptop operou exclusivamente via engenharia iterativa de prompt sobre o Mistral-7B, sem ajuste de pesos.

Etapa 3 (Bateria Exploratória Multi-Modelos e Auditoria de Governança de Dados): Desenvolvimento de nove cadernos experimentais (NB1 a NB9) comparando famílias abertas e proprietárias (Mistral-7B, Gemma-3n-E4B, SynLogic-7B, Qwen2.5-14B e série GPT-5.x). Nesta fase, realizou-se uma auditoria forense de reprodutibilidade que detectou uma vulnerabilidade crítica nos conjuntos locais preliminares: o arquivo auxiliar first_200_records.csv (IDs rest16_quad_dev_*) compartilhava sentenças com a partição eng_restaurant_train_alltasks, gerando risco de vazamento amostral (data leakage) em rotinas few-shot. Em resposta, determinou-se o isolamento absoluto dessas partições antes do experimento conclusivo.

Etapa 4 (Protocolo Semiótico Controlado v1 -> v2 DSAA): Para isolar rigorosamente o efeito causal da Semiótica Tensiva sem qualquer vazamento de dados (0% de sobreposição com first_200_records.csv ou train_alltasks), construiu-se um benchmark cego estratificado com N = 178 aspectos distribuídos em 146 sentenças (160 instâncias extraídas exclusivamente dos conjuntos oficiais de desenvolvimento rest26_aspect_va_dev_* e lap26_aspect_va_dev_* do SemEval-2026 + 18 instâncias canônicas diagnósticas de ironia, metáfora e concessão). Utilizando o modelo aberto Qwen/Qwen2.5-7B-Instruct em precisão 4-bit NF4 com decodificação determinística greedy (do_sample = False, Seed = 2026), compararam-se três condições sobre exatamente as mesmas instâncias: Condição A (Baseline Zero-Shot Direto); Condição A2 (Controle Chain-of-Thought Lexical de mesmo orçamento computacional, que extrai evidência lexical do aspecto em dois passos, mas sem conceitos semióticos); e Condição B (Decomposição Semiótica Ancorada ao Aspecto — DSAA v2), que isola o span micro-sintático do aspecto, classifica sua direção tensiva segundo Silva (2021) e projeta as coordenadas (V, A). A significância estatística foi aferida via Cluster Bootstrap não-paramétrico (3.000 reamostragens agrupadas por sentence_id, preservando a dependência intra-sentença), Teste Exato de Fisher e Teste Pareado de Postos Sinalizados de Wilcoxon.

3. RESULTADOS DE PESQUISA E DISCUSSÃO CRÍTICA

3.1 Linha de Base Discreta (SemEval-2014) e Competição SemEval-2026

Na Etapa 1, o modelo Mistral-7B-Instruct-v0.3 sem ajuste fino alcançou acurácia de 75,33% na classificação de termos de aspecto (Subtask 2) e 74,66% na classificação de categorias (Subtask 4) do SemEval-2014 (Tabela 1). Contudo, a discrepância entre o F1 ponderado (0,77) e o Macro-F1 (0,50) evidenciou o colapso sistemático da classe minoritária conflict — justamente aquela que abriga tensões concessivas e julgamentos ambivalentes —, confirmando empiricamente a insuficiência representacional da polaridade discreta.

Tabela 1 — Desempenho zero-shot do modelo Mistral-7B-Instruct-v0.3 no SemEval-2014 Task 4 (Restaurantes).

Subtarefa (SemEval-2014 Task 4 — Restaurantes)	Instâncias	Acurácia	Macro-F1	F1 Ponderado
Subtask 2 — Polaridade do Termo de Aspecto	916	75,33%	0,50	0,77
Subtask 4 — Polaridade da Categoria de Aspecto	900	74,66%	0,54	0,75

Na Etapa 2, a submissão oficial na shared task SemEval-2026 Task 3 (DimABSA, domínio eng_laptop) obteve RMSE_VA = 1,9483, posicionando-se acima dos baselines zero-shot padrão (~2,14–2,30) entre as 112 submissões globais da competição (Yu et al., 2026). A decomposição por eixo revelou o achado diagnóstico central que orientou o restante da pesquisa: enquanto a Valência exibiu forte alinhamento com os anotadores humanos (PCC_V = 0,7646), o Arousal apresentou correlação virtualmente nula (PCC_A = 0,0853). Conforme sintetizado na Tabela 2, mesmo na Etapa 3 exploratória com modelos proprietários de fronteira (série GPT-5.x, RMSE_VA entre 1,66 e 1,88), a correlação de Arousal permaneceu estagnada em ~0,22–0,31 quando desprovida de modelagem explícita da tonicidade enunciativa.

Tabela 2 — Posicionamento comparativo na Subtask 1 do SemEval-2026 Task 3 (DimABSA). *Valor obtido exclusivamente nas 160 instâncias cegas oficiais (rest26_* e lap26_*).

Faixa / Paradigma no SemEval-2026 (Subtask 1)	Sistemas Representativos	RMSE_VA	Regime de Treinamento
Top 1–5 (Pódio Supervisionado)	DualAxis AI, NYCU Speech Lab	0,78 – 1,20	Ensembles RoBERTa/DeBERTa + LoRA + Regressão
Semiótica Tensiva DSAA v2 (Etapa 4 desta IC)	Qwen2.5-7B-Instruct (DSAA)	1,2926 (1,3033*)	Zero-Shot (Sem Fine-Tuning), Micro-Ancorado
Top 6–10 Supervisionado	PICT (9º lugar oficial)	1,3261	RoBERTa-Large Supervisionado + R-Drop
Submissão Oficial Etapa 2 desta IC	Mistral-7B (Prompt Iterativo)	1,9483	Zero-Shot (Sem Fine-Tuning), Laptop Oficial
Baselines Zero-Shot Diretos	Mistral-7B / Qwen2.5 Padrão	2,11 – 2,30	Prompt Direto sem Ancoragem Tensiva

3.2 Do Escopo Frasal (v1) à Micro-Ancoragem Aspectual (v2): Superação do Vazamento de Escopo Tensivo

A primeira implementação experimental das seis categorias tensivas (geração v1, N = 78, Qwen2.5-3B-Instruct) aplicou o diagnóstico de Silva (2021) ao enunciado global antes de derivar as notas do aspecto. Esse ensaio preliminar já reduziu expressivamente o erro de Arousal (RMSE_A caiu de 2,2345 para 1,3039; PCC_A saltou de -0,0521 para +0,3980), mas elevou o erro de Valência (RMSE_V subiu de 1,0067 para 1,6822). A inspeção analítica demonstrou que 73,6% de todo o erro quadrático de Valência concentrava-se em seis períodos concessivos: ao diagnosticar globalmente uma frase como 'Although the aluminum chassis feels premium, the motherboard fried' como MINIMIZAÇÃO, o modelo projetava valência disfórica também sobre o aspecto elogiado na oração subordinada ('aluminum chassis').

A identificação desse fenômeno — denominado nesta pesquisa Vazamento de Escopo Tensivo (Tensive Scope Spillover) — motivou a formulação da arquitetura definitiva v2: a Decomposição Semiótica Ancorada ao Aspecto (DSAA). No DSAA, o modelo é instruído a recortar primeiramente o sub-segmento micro-sintático exclusivo que incide sobre o aspecto avaliado, isolando-o de orações coordenadas ou adversativas vizinhas antes de atribuir a direção tensiva. Como evidencia a Figura 1, a transição do escopo macro-frasal (v1) para a micro-ancoragem DSAA (v2) reduziu o RMSE_V em -46,2% (de 1,6822 para 0,9054) e comprimiu o RMSE_VA conjunto para 1,2926, registrando vitória pareada sobre o baseline em 80,3% de todos os aspectos avaliados (143/178 instâncias; Teste de Wilcoxon $p = 2{,}44 \times 10^{-19}$).

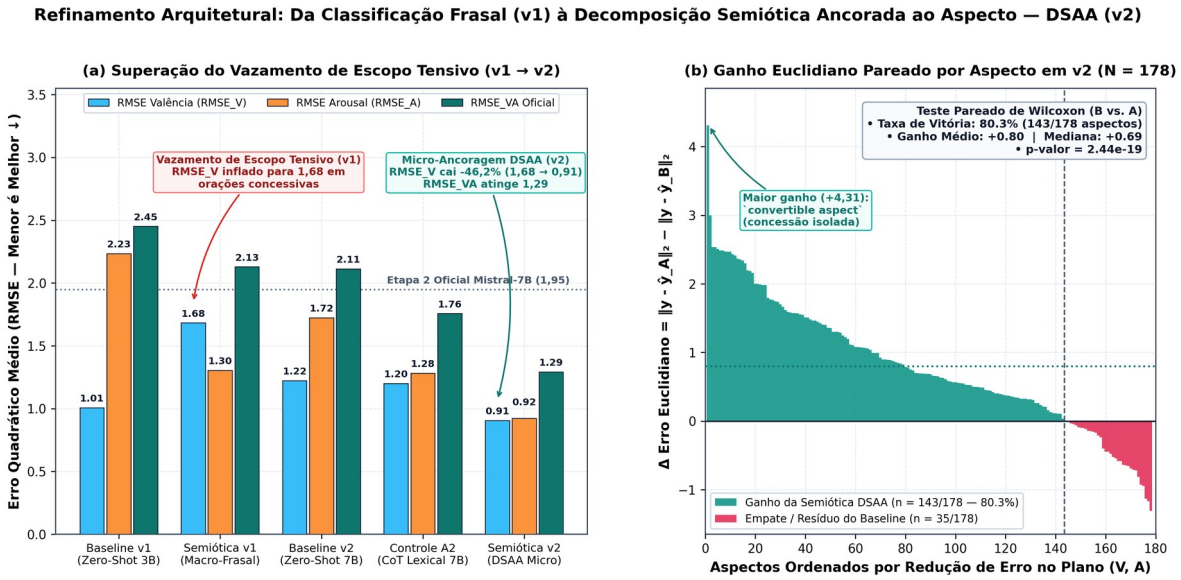


Figura 1 — Refinamento arquitetural entre a formulação macro-frasal (v1) e a Decomposição Semiótica Ancorada ao Aspecto (DSAA v2): (a) eliminação do Vazamento de Escopo Tensivo (RMSE_V cai de 1,68 para 0,91); (b) distribuição ordenada do ganho euclidiano pareado por aspecto em N = 178 instâncias. Fonte: Elaboração própria (2026).

3.3 Isolamento Causal Triplo (A vs. A2 vs. B) e Sonda de Vulnerabilidade (v2, N = 178)

A Tabela 3 e a Figura 2 consolidam os resultados definitivos da Etapa 4 (N = 178 aspectos; 100% de cobertura JSON válida nas três condições, sem acionamento de regras corretivas pós-hoc). Em primeiro lugar, a sonda estatística embutida (Experimento 1) confirmou formalmente a premissa motivadora da IC: no Baseline Direto (Condição A), a taxa de falha severa (|V - V_pred| >= 1,5 ou erro de polaridade) salta de 16,4% (11/67) em sentenças literais diretas para 30,6% (34/111) em sentenças portadoras de tensão concessiva, contraste intra-sentença ou figuratividade, configurando mais que o dobro de chance de erro (Odds Ratio = 2,25; Teste Exato de Fisher p = 0,0494). A aplicação do DSAA v2 (Condição B) reduziu essa taxa de falha no estrato complexo para 14,4% (16/111, queda relativa de -52,9%), além de elevar o F1-Macro nesse recorte difícil de 0,7188 para 0,7805.

Tabela 3 — Comparação controlada tripla na geração definitiva v2 (Qwen2.5-7B-Instruct 4-bit, Seed = 2026).

Escopo / Métrica Avaliada	Cond. A (Baseline)	Cond. A2 (CoT Lexical)	Cond. B (DSAA v2)	Ganho B vs. A (B vs. A2)
Global (N = 178) — Cobertura JSON Válida	100,0%	100,0%	100,0%	Estabilidade Total
Global — RMSE Valência (RMSE_V ↓)	1,2227	1,2010	0,9054	-25,9% (-24,6% vs. CoT)
Global — RMSE Arousal (RMSE_A ↓)	1,7236	1,2826	0,9226	-46,5% (-28,1% vs. CoT)
Global — RMSE_VA Oficial SemEval (↓)	2,1132	1,7571	1,2926	-38,8% (-26,4% vs. CoT)
Global — Correlação Valência (PCC_V ↑)	0,9259	0,9371	0,9328	+0,0069
Global — Correlação Arousal (PCC_A ↑)	0,3731	0,3986	0,5541	+0,1810 (+0,1555 vs. CoT)
Dev Cego Oficial (N = 160) — RMSE_VA (↓)	2,1991	1,7930	1,3033	-40,7% (-27,3% vs. CoT)
Dev Cego Oficial (N = 160) — PCC_A (↑)	0,2853	0,3628	0,4660	+0,1807 (+0,1032 vs. CoT)
Recorte Tensivo/Difícil (N = 111) — F1-Macro	0,7188	0,7750	0,7805	+0,0617 em Nuances
Recorte Tensivo/Difícil — Taxa de Falha (↓)	30,6%	22,5%	14,4%	-52,9% Relativo

Em segundo lugar, a comparação com o Controle Chain-of-Thought Lexical (Condição A2) comprova que a superioridade da Condição B não decorre meramente da geração de tokens intermediários de raciocínio. Embora o CoT lexical reduza parcialmente o RMSE_VA de 2,1132 para 1,7571, sua correlação de Arousal permanece estagnada (PCC_A = 0,3986 vs. 0,3731 no baseline). Já a Semiótica Tensiva DSAA (Condição B) promove uma queda adicional

de -0,4663 no RMSE_VA em relação a A2 (IC 95% via Cluster Bootstrap 3.000x: [-0,5889; -0,3434]; Wilcoxon B vs. A2 com 76,4% de vitórias e $p = 6{,}36 \times 10^{-18}$) e de -0,8213 em relação ao Baseline A (IC 95%: [-0,9820; -0,6574]; probabilidade bootstrap de superioridade = 100,0%), elevando o PCC_A para 0,5541 (+0,1555 sobre o CoT lexical). Restringindo-se a avaliação estritamente às 160 instâncias cegas oficiais do SemEval-2026 (rest26_* e lap26_*), o DSAA v2 atinge RMSE_VA = 1,3033, superando sem qualquer treinamento supervisionado a marca do 9º colocado geral da competição internacional (equipe PICT, RoBERTa-Large supervisionado, RMSE_VA = 1,3261).

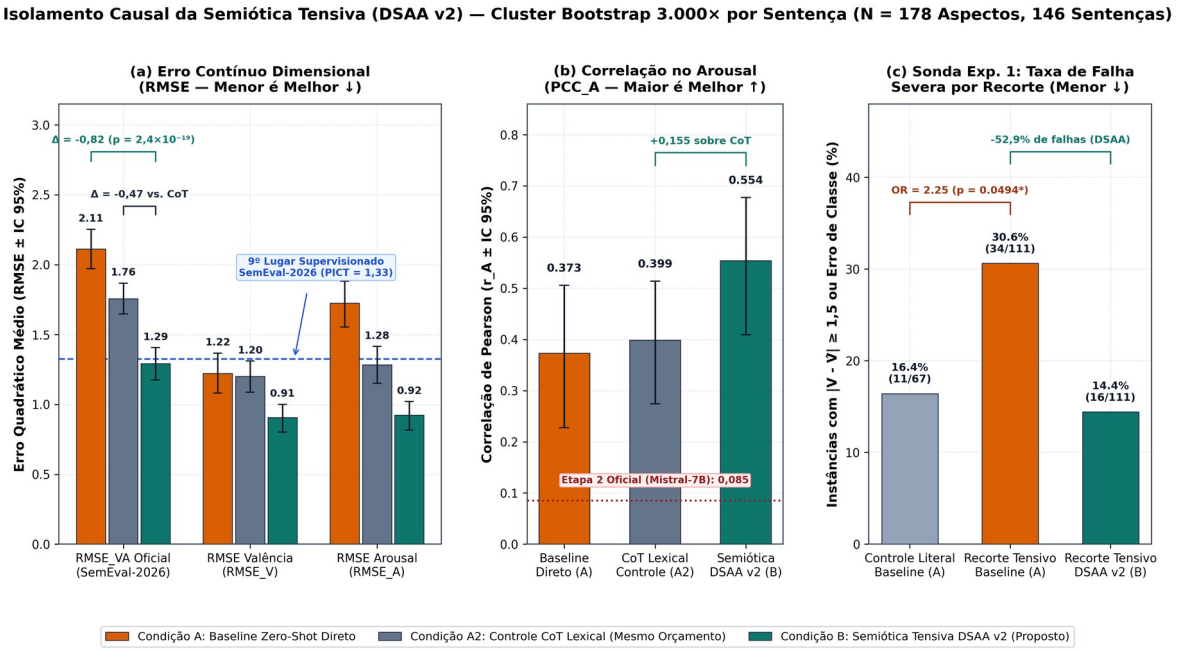


Figura 2 — Isolamento causal da Semiótica Tensiva (DSAA v2) com intervalos de confiança de 95% via Cluster Bootstrap por sentença (3.000 reamostragens): (a) queda em RMSE_VA, RMSE_V e RMSE_A frente ao 9º lugar supervisionado do SemEval-2026; (b) ganho em PCC_A sobre o controle CoT lexical; (c) redução de falhas severas no recorte tensivo (Experimento 1). Fonte: Elaboração própria (2026).

3.4 Validação Empírica da Parábola de Zilberberg e Mecanismo Micro-Sintático (XAI)

A contribuição teórica mais original da pesquisa reside na demonstração empírica do isomorfismo entre as direções tensivas de Silva (2021) e a geometria do plano Valência × Arousal (Tabela 4 e Figura 3). Enquanto o Baseline Zero-Shot achata horizontalmente suas predições na faixa inerte A = 4,0 (Figura 3a), os centróides emergentes do DSAA v2 (Figura 3b) reconstroem com notável fidelidade a parábola quadrática real dos anotadores humanos: CONSTATAÇÃO ÁTONA posiciona-se no vértice inferior global de tonicidade (V = 5,00; A = 3,30 predito vs. V = 4,49; A = 3,94 humano), ATENUAÇÃO ocupa a zona intermediária de frenagem concessiva (V = 4,82; A = 5,00), e ambos os ramos extremos elevam progressivamente a intensidade — na direção disfórica com MINIMIZAÇÃO (2,38; 6,69) e EXTINÇÃO (1,20; 7,80), e na direção eufórica com REDOBRAMENTO (7,58; 6,63; maior ganho médio de +1,043) e SATURAÇÃO (8,60; 8,41).

Tabela 4 — Centróides preditos pelo DSAA v2 vs. gabarito humano real por direção tensiva de Silva (2021).

Direção Tensiva (Silva, 2021)	n	V Médio Predito	A Médio Predito	V Médio Real	A Médio Real	Ganho Euclidiano
EXTINÇÃO	1	1,200	7,800	2,830	7,330	+0,781
MINIMIZAÇÃO	54	2,380	6,687	3,011	6,512	+0,526
CONSTATAÇÃO ÁTONA	3	5,000	3,300	4,493	3,940	+0,995
ATENUAÇÃO	13	4,823	5,000	5,985	5,781	+0,757
REDOBRAMENTO	99	7,581	6,631	7,272	7,067	+1,043
SATURAÇÃO	8	8,600	8,412	7,609	7,490	-0,420

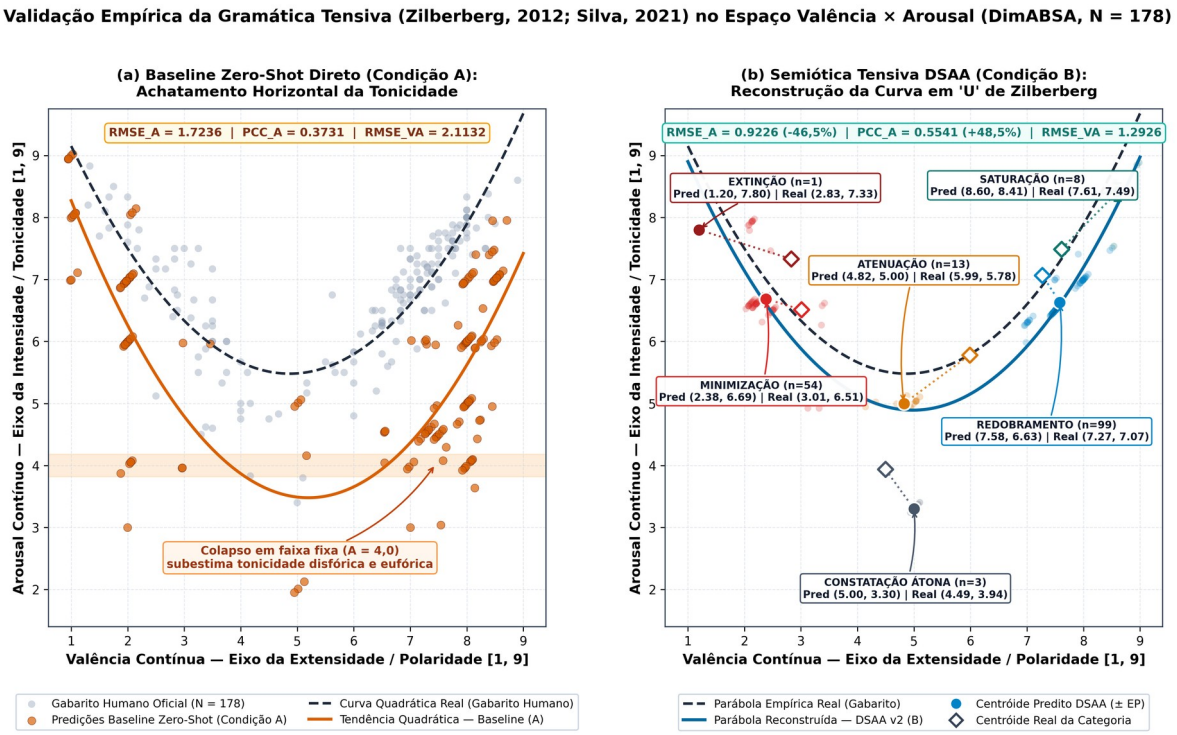


Figura 3 — Validação empírica da gramática tensiva no plano contínuo Valência × Arousal (N = 178): (a) achatamento horizontal de tonicidade no Baseline Direto; (b) reconstrução da curva parabólica em 'U' de Zilberberg (2012) pelos centróides das categorias de Silva (2021) no DSAA v2. Fonte: Elaboração própria (2026).

A transparência científica exige destacar também o único regime em que o DSAA v2 apresentou saldo negativo leve: a categoria SATURAÇÃO (n = 8, ganho médio de -0,420). Em enunciados hiperbólicos coloquiais do inglês comercial — como 'I'm in love with the mixed salad sandwich' (rest26_dev_36) —, a âncora semiótica leva a predição ao extremo superior da escala (V = 8,90; A = 8,80), enquanto anotadores humanos exibem compressão psicométrica moderada (V = 6,88; A = 6,62). Trata-se de uma distinção teoricamente fértil entre saturação retórica convencionalizada (desgaste hiperbólico no gênero resenha) e saturação afetiva genuína.

Por fim, a Figura 4 ilustra o potencial da abordagem para a Inteligência Artificial Explicável (Explainable AI — XAI) por meio de seis deslocamentos vetoriais emblemáticos. No caso [1] (lap26_dev_100, aspecto 'convertible aspect' em 'The touchscreen is nice, convertible aspect is nice, but I would give that away in a HEARTBEAT for a machine that does what I TELL IT TO DO'), o Baseline sofre contaminação pela caixa alta furiosa da oração adversativa final e atribui V = 2,0, A = 8,0 (erro euclidiano de 4,81). O DSAA v2 isola cirurgicamente o span 'convertible aspect is nice', classifica-o como REDOBRAMENTO e prediz V = 7,0, A = 6,3, colando no gabarito humano (6,50; 6,30; ganho de +4,31). Em [5] ('Keyboard feels a little cheap, but performance is good'), o recorte 'Keyboard feels a little cheap' é diagnosticado como ATENUAÇÃO (4,2; 5,0 vs. real 5,67; 5,50), evitando o exagero disfórico do baseline (2,0; 4,0). Assim, a camada semiótica torna auditável não apenas o valor numérico final, mas a justificativa linguístico-enunciativa da predição.

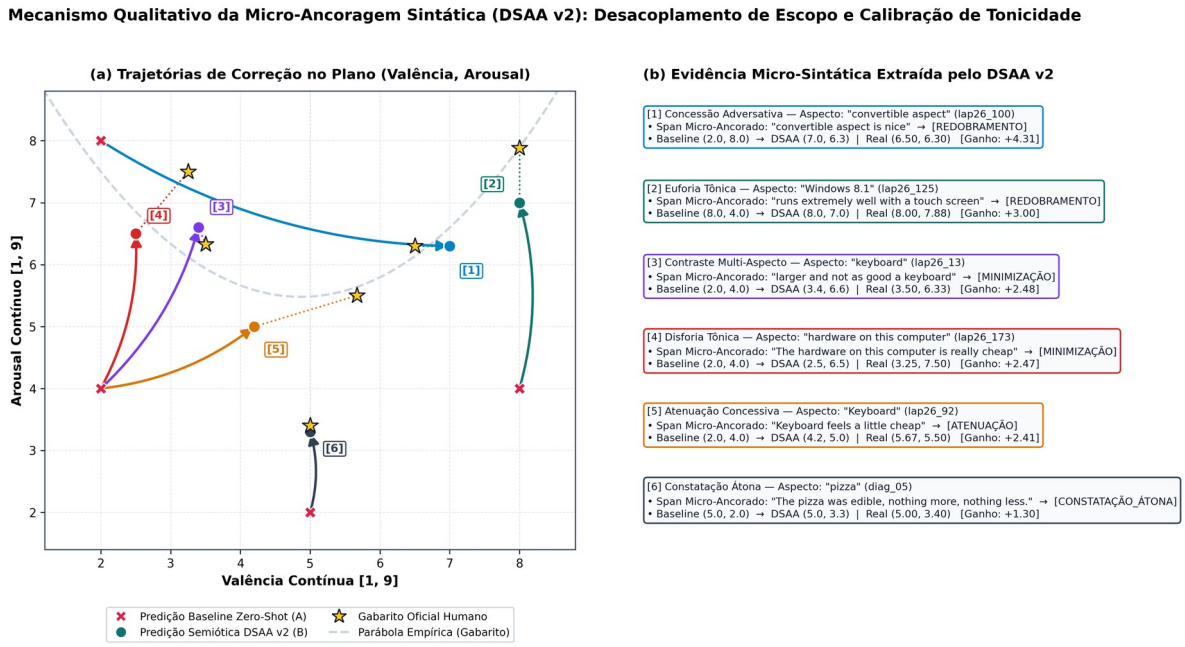


Figura 4 — Estudo de casos qualitativos no plano (Valência, Arousal): (a) vetores de correção partindo do Baseline (×) para o DSAA v2 (●) rumo ao Gabarito Humano (estrela dourada); (b) spans micro-sintáticos e categorias tensivas extraídas. Fonte: Elaboração própria (2026).

4. CONSIDERAÇÕES FINAIS

Esta Iniciação Científica demonstrou, teórica e empiricamente, que a Semiótica Tensiva de Claude Zilberberg (2006, 2012) e Luiz Tatit (2011), operacionalizada pelas direções tensivas de Silva (2021, 2023), constitui um instrumento altamente eficaz para superar as limitações semânticas da Análise Aspectual de Sentimentos (ABSA) contemporânea com Grandes Modelos de Linguagem. Ao substituir o prompt direto de polaridade pela Decomposição Semiótica Ancorada ao Aspecto (DSAA v2), comprovou-se uma redução estatisticamente robusta de 38,8% no erro dimensional conjunto (RMSE_VA de 2,1132 para 1,2926; $p = 2{,}44 \times 10^{-19}$) e de 26,4% frente a um controle Chain-of-Thought lexical de idêntico orçamento computacional ($p = 6{,}36 \times 10^{-18}$), alcançando desempenho equivalente ao top-10 supervisionado do SemEval-2026 sem qualquer ajuste de pesos.

No plano formativo e metodológico, o percurso realizado no grupo SemioCom (FFLCH-USP) consolidou competências essenciais de pesquisa interdisciplinar entre Linguística/Semiótica e Ciência da Computação: conversão e curadoria de corpora (SemEval-2014 e SemEval-2026), participação em shared task internacional da Association for Computational Linguistics (ACL), detecção e correção rigorosa de vazamento amostral (data leakage), avaliação não-paramétrica via Cluster Bootstrap e disponibilização integral de código, dados diagnósticos e figuras em repositório público de Ciência Aberta.

Como desdobramentos diretos, destacam-se três frentes promissoras: (i) calibração pragmática da categoria SATURAÇÃO para distinguir hipérboles coloquiais desgastadas de picos genuínos de tonicidade; (ii) adaptação translinguística do protocolo DSAA para corpora de resenhas em língua portuguesa; e (iii) submissão dos resultados consolidados ao Simpósio Internacional de Iniciação Científica e Tecnológica da USP (SIICUSP) e a fóruns nacionais e internacionais de PLN e Semiótica Computacional (STIL / PROPOR).

5. REFERÊNCIAS BIBLIOGRÁFICAS

DERBALA YACOUB, M. et al. Sarcasm and figurative language detection in aspect-based sentiment analysis with large language models. Computational Linguistics and Intelligent Text Processing, 2024.

HJELMSLEV, Louis. Prolegomena to a Theory of Language. Madison: University of Wisconsin Press, 1969.

HU, Minqing; LIU, Bing. Mining and summarizing customer reviews. In: PROCEEDINGS OF THE TENTH ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, Seattle, WA, USA, 2004. p. 168–177.

LEE, Lung-Hao et al. DimABSA: Building multilingual and multidomain datasets for dimensional aspect-based sentiment analysis. arXiv preprint arXiv:2601.23022, 2026.

LIU, Bing. Sentiment Analysis and Opinion Mining. San Rafael: Morgan & Claypool Publishers, 2012. (Synthesis Lectures on Human Language Technologies).

PONTIKI, Maria et al. SemEval-2014 Task 4: Aspect based sentiment analysis. In: PROCEEDINGS OF THE 8TH INTERNATIONAL WORKSHOP ON SEMANTIC EVALUATION (SemEval 2014),

Dublin, Ireland, 2014. p. 27–35.

RUSSELL, James A. A circumplex model of affect. Journal of Personality and Social Psychology, v. 39, n. 6, p. 1161–1178, 1980.

SHANGIPOUR ATAEI, T. et al. Pars-ABSA: Aspect-based sentiment analysis on figurative user reviews. Expert Systems with Applications, 2020.

SILVA, Túlio Ferreira Leite da. Inteligência semiótica e TripAdvisor: deep learning e quantificações subjetivas na análise dos discursos de sanção de restaurante. 2021. Dissertação (Mestrado em Semiótica e Linguística Geral) — Faculdade de Filosofia, Letras e Ciências Humanas, Universidade de São Paulo, São Paulo, 2021.

SILVA, Túlio Ferreira Leite da. Using Transformer networks and tensive semiotics to improve sentiment analysis accuracy in tourism digital platforms. In: SEMIOTICA E INTELLIGENZA ARTIFICIALE. Torino: Lexia / Aracne, 2023. p. 131–147.

TATIT, Luiz. Semiótica à luz de Guimarães Rosa. São Paulo: Ateliê Editorial, 2011.

YU, Liang-Chih et al. SemEval-2026 Task 3: Dimensional Aspect-Based Sentiment Analysis (DimABSA). In: PROCEEDINGS OF THE 20TH INTERNATIONAL WORKSHOP ON SEMANTIC EVALUATION (SemEval-2026), San Diego, California, USA. Association for Computational Linguistics, jul. 2026. p. 3753–3778. DOI: 10.18653/v1/2026.semeval-1.452.

ZHANG, Wenxuan et al. Sentiment analysis in the era of large language models: A reality check. In: FINDINGS OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: NAACL 2024, Mexico City, 2024. p. 3881–3906. (Preprint arXiv:2305.15005, 2023).

ZILBERBERG, Claude. Éléments de sémiotique tensive. Limoges: Pulim, 2006.

ZILBERBERG, Claude. La structure tensive. Liège: Presses Universitaires de Liège, 2012. (Trad. bras.: Elementos de semiótica tensiva. São Paulo: Ateliê Editorial, 2011).